

Wczesne ostrzeganie przed zapchaniem młyna węglowego

Identyfikacja obiektu i model predykcyjny na danych DCS

Jakub Wróblewski Mateusz Smardzewski

Politechnika Warszawska, Wydz. Elektroniki i Technik Informacyjnych
Automatyka i Robotyka — Metody Identyfikacji

czerwiec 2026

Plan

- ① Problem
- ② Dane i definicja zdarzenia
- ③ Rozwiązanie
- ④ Wyniki
- ⑤ Podsumowanie

Problem — w jednym zdaniu

Cel

Przewidzieć **zapchanie (dławienie) młyna węglowego** z minutowych danych DCS na tyle wcześniej, by zdążyć zareagować przed awaryjnym odcięciem podajnika.

Dlaczego to ważne (widownia zna temat)


- zapchanie $\Rightarrow$ spadek wydajności mielenia, wahania mocy bloku,
- kończy się **awaryjnym cięciem podajnika** i odstawieniem młyna,
- dziś wykrywane *po fakcie* — operator reaguje, gdy już dławi.

Teza projektu

- prekursorzy są widoczne **60–120 min** przed kulminacją,
- więc jest fizyczna podstawa do **wczesnego ostrzegania**,
- zadanie: zamienić tę fizykę w działający alarm.

Dane: blok 1, młyny wentylatorowe MW1–MW4, luty 2026, rozdzielczość 1 min.

Anatomia epizodu — fizyka, na której stoi rozwiązanie



Powtarzalna sekwencja (MW3, 15.02):

- 1 regulator wentylacji otwiera kierownicę aż do **wysycenia 100%**,
- 2 mimo to **przepływ spada** poniżej zadanego (rośnie opór),
- 3 **moc młyna rośnie**, temperatura mieszanki spada,
- 4 automatyka **awaryjnie tnie podajnik** — młyn się oczyszcza.

To *kierowany* proces fizyczny, a nie szum — dlatego daje się go modelować.

Dane — krótko

Co mamy

- 4 młyny $\times$ ~ 38 sygnałów, 1 min, 01–27.02,
- $\sim 37\,440$ minut/młyn (~ 40 MB),
- sygnały kluczowe: regulacja wentylacji (pomiar/zadana/sterowanie), moc młyna, podajnik, temperatura mieszanki.

Pułapki (obsłużone w loader.py)

- kodowanie cp1250,
- **mieszane formaty czasu** w jednym pliku,
- braki N_A/NaN ($\sim 3\%$).

Kluczowy fakt

Brak dziennika zdarzeń DCS $\Rightarrow$ **zdarzenia trzeba zdefiniować sygnałowo**. W lutym wszystkie epizody wystąpiły na MW3 i MW4 — **5 silnych** epizodów + kilka mikrozdarzeń.


Definicja zdarzenia i etykietowanie

Zdarzenie = (młyn pracuje, moc >20 kW)

oraz:

- **D1**: deficyt wentylacji $>20\%$ przez ≥ 5 min przy sterowaniu $\geq 98\%$,
- **D2**: awaryjne cięcie podajnika (≥ 25 pkt w ≤ 3 min),
- **D3**: skrajna moc młyna przy deficycie.

Silny epizod = ≥ 3 min D1 (ma fazę narastania $\Rightarrow$ *przewidywalny*). Mikro zdarzenia (nagłe tripy) **wyłączone z uczenia i oceny** — z danych 1-min nieprzewidywalne.



Etykieta: $y(t) = 1$, gdy silny epizod zacznie się w ciągu

60 min.

Inżynieria cech — fizyka zaszyta w liczbach

39 cech, wyłącznie z przeszłości (brak wycieku przyszłości)

- poziomy, zmiany (15/30/60 min), średnie kroczące,
- wszystkie młyny sklejone w jeden zbiór (cechy niezależne od numeru młyna).

Cechy fizyczne (sedno)

- **deficyt** = $\frac{\text{zadana} - \text{pomiar}}{\text{zadana}}$ wentylacji,
- **drożność** = $\frac{\text{przepływ}}{\text{wyjście regulatora}}$ (proxy oporu),
- **moc_na_węgiel** = $\frac{\text{moc młyna}}{\text{prędkość podajnika}}$,
- minuty wysycenia regulatora, niestabilność mocy (std 30 min).

Bilans zbioru

~131 700 minut, **300 minut pozytywnych (0,23%)**, 5 silnych epizodów — klasa skrajnie rzadka.

Model i walidacja

Wybór: **LightGBM** + reguła fizyczna

- gradient boosting na cechach fizycznych: interpretowalny, trenuje się w sekundy na CPU,
- reguła fizyczna jako **niezależny watchdog** (poziom odniesienia).

Dlaczego nie sieć głęboka?

- **5 zdarzeń / 1 miesiąc** — o 1–2 rzędy za mało na deep learning,
- GPU zbędne (dane miesiąca ~40 MB).


Uczciwa walidacja

- **leave-one-day-out** (27 foldów, grupowanie po dniach) $\Rightarrow$ brak wycieku czasowego,
- cechy liczone tylko z przeszłości,
- wykluczone: postoje, 60 min po rozruchu, epizod + rekonwalescencja.

Tłumienie fałszywych alarmów

- alarm dopiero po **3 kolejnych minutach** score $\geq$ próg.

Identyfikacja obiektu — zapchanie = spadek wzmocnienia



Kanał **kierownica** → **przepływ** traci wzmocnienie statyczne (drożność y/u) tuż przed epizodem:

młyn	zdrowy	przed
MW3	0,506	0,277 (-45%)
MW4	0,917	0,152 (-83%)

Tor temperatury (FOPDT, pętla zamknięta): MW3 $K \approx 1$, $T \approx 23$ min. To *ten sam* sygnał, który widzi model.


Wyniki — porównanie modeli

Model	PR-AUC	ROC-AUC	Epizody	Śr. wyprz. [min]	Fałsz./dobę/młyn
reguła fizyczna	—	—	5/5	48,8	0,074
LightGBM (cechy, 5-fold)	0,286	0,931	4/5	33,0	0,046
LightGBM, LODO (27 foldów)	0,359	0,953	5/5	30,0	0,056
hybryda (LightGBM $\vee$ reguła), LODO	—	—	5/5	51,0	0,093

- Model finalny (LODO, próg 0,5, alarm po 3 min): **5/5 epizodów, śr. 30 min wyprzedzenia, 0,056 fałszywej serii/dobę/młyn.**
- Hybryda z regułą wydłuża wyprzedzenie do **~51 min** kosztem nieco większej liczby fałszywych alarmów.
- Surowy klasyfikator minutowy jest słaby (PR-AUC $\sim$ 0,36 przy 0,23% klasy) — siła leży w *post-processingu* (próg + seria 3 min).

Jak to wygląda w działaniu (walidacja LODO)


Wyjście modelu LightGBM w walidacji leave-one-day-out (predykcje pozapróbkowe)



Wyjście modelu LightGBM (out-of-fold) dla MW3 i MW4: szpilki score wyprzedzają pionowe znaczniki epizodów.

Co model faktycznie "widzi"

LightGBM: 15 najważniejszych cech (model finalny)




Najważniejsze cechy:

- pomiar przepływu wentylacji (poziom i średnia 15 min),
- średnia moc młyna (60 min),
- zmiana odchyłki temperatury mieszanki (30 min),
- minuty deficytu, niestabilność mocy, drożność.

Wszystkie czołowe cechy mają **jasną interpretację fizyczną** — model zgadza się z analizą identyfikacyjną.

Sieci neuronowe — świadomy kontrprzykład

Niestabilność uczenia sieci przy 5 zdarzeniach (fold 4 nie zawiera żadnego zdarzenia)



MLP i LSTM przy identycznej walidacji:

- **brak spójnej przewagi** nad LightGBM,
- uczenie **niestabilne** (krzywe skaczą — za mało zdarzeń),
- zdarzeniowo podobna wykrywalność, ale więcej fałszywych alarmów.

Wniosek: przy 5 zdarzeniach *prostszy, fizyczny* model wygrywa.

Ograniczenia i co dalej

Ograniczenia (uczciwie)

- etykiety **heurystyczne** — wymagają potwierdzenia przez obsługę bloku,
- **5 zdarzeń / 1 miesiąc / 2 młyny** — na granicy istotności statystycznej,
- to *studium wykonalności*, nie model produkcyjny.

Co dalej

- 6–12 miesięcy danych (sezonowość, wilgotność węgla),
- dołączyć dane ogólnokotłowe i KPI (obciążenie bloku),
- wdrożenie online: cechy w oknie kroczącym + reguła jako watchdog,
- przy >50 zdarzeniach — testy modeli sekwencyjnych (TCN/LSTM).

Wnioski

Najważniejsze

- Zapchanie ma **powtarzalny, fizyczny przebieg** i mierzalne prekursorsy 60–120 min wcześniej.
- Identyfikacyjnie: epizod = **spadek wzmocnienia** kanału kierownica → przepływ (MW3 –45%, MW4 –83%).
- Finalny model (LightGBM, 39 cech fizycznych, LODO): **5/5 epizodów, śr. 30 min wyprzedzenia, 0,06 fałszywej serii/dobę/młyn**; hybryda z regułą — do ~51 min.
- Sieci neuronowe nie dają przewagi przy tej liczbie zdarzeń.

Dziękujemy — pytania?