

Politechnika Warszawska
Wydział Elektroniki i Technik Informacyjnych
kierunek: Automatyka i Robotyka

przedmiot: **Metody Identyfikacji**

Predykcja zapchania młyna węglowego w elektrociepłowni na podstawie danych procesowych

analiza identyfikacyjna obiektu i porównanie modeli
wczesnego ostrzegania

Jakub Wróblewski
Mateusz Smardzewski

Warszawa, czerwiec 2026

Spis treści

1	Wstęp i cel projektu	2
2	Obiekt i dane pomiarowe	2
2.1	Zespół młynowy jako obiekt	2
2.2	Dane	2
3	Analiza identyfikacyjna obiektu	3
3.1	Charakterystyka statyczna kanału kierownica $\rightarrow$ przepływ	3
3.2	Odpowiedź skokowa i model FOPDT toru temperatury	4
3.3	Rekurencyjna identyfikacja ARX i problem pętli zamkniętej	5
4	Definicja zdarzenia i etykietowanie danych	6
4.1	Anatomia epizodu	6
4.2	Sygnałowa definicja zdarzenia	7
4.3	Schemat etykietowania	8
5	Modele predykcyjne	8
5.1	Cechy	8
5.2	Reguła fizyczna (poziom odniesienia)	8
5.3	LightGBM	9
5.4	Sieci neuronowe (kontrprzykład)	9
6	Metodyka oceny	9
7	Wyniki	10
7.1	Porównanie modeli	10
7.2	Sieci neuronowe — analiza kontrprzykładu	11
8	Dyskusja	12
9	Wnioski	12
A	Reprodukcja wyników	13

1 Wstęp i cel projektu

Zespoły młynowe (potocznie nazywane także kruszarkami węgla) są jednym z najbardziej awaryjnych elementów kotłów pyłowych. Zapchanie młyna — nadmierne nagromadzenie węgla w komorze mielenia i pyłoprzewodach — prowadzi do gwałtownego wzrostu mocy napędu, utraty wentylacji, a w skrajnym przypadku do awaryjnego odstawienia młyna i ograniczenia mocy bloku. Celem projektu jest zbadanie, czy na podstawie standardowych, minutowych danych procesowych z systemu DCS można *przewidzieć* nadchodzące zapchanie z wyprzedzeniem pozwalającym obsłużyć na reakcję (odciążenie młyna), zanim zadziała automatyka zabezpieczeniowa.

Projekt realizuje pełny tok postępowania identyfikacyjnego:

1. analizę eksploatacyjnych danych pomiarowych obiektu (bez eksperymentu czynnego),
2. identyfikację charakterystyk obiektu: charakterystyki statycznej, odpowiedzi skokowej toru regulacji (model FOPDT) oraz rekurencyjną identyfikację modelu ARX z dyskusją ograniczeń identyfikacji w zamkniętej pętli regulacji,
3. interpretację zapchania jako *dryfu parametrów obiektu* (spadku wzmocnienia statycznego kanału wentylacji),
4. budowę i porównanie modeli predykcyjnych: reguły fizycznej, modelu gradient boosting (LightGBM) oraz — jako świadomego kontrprzykładu — sieci neuronowych (MLP, LSTM),
5. ocenę zdarzeniową jakości predykcji (wykrywalność epizodów, czas wyprzedzenia, częstość fałszywych alarmów).

2 Obiekt i dane pomiarowe

2.1 Zespół młynowy jako obiekt

Analizowany blok wyposażony jest w cztery zespoły młynowe MW1–MW4 (młyny wentylatorowe). Węgiel podawany jest podajnikiem o regulowanej prędkości, mielony i jednocześnie transportowany strumieniem powietrza wytwarzanym przez wentylator młynowy. O punkcie pracy decydują dwa tory regulacji (UAR):

- **tor wentylacji:** regulator utrzymuje zadany przepływ mieszanki przez młyn, sterując kierownicą (łopatkami kierującymi) wentylatora,
- **tor temperatury mieszanki pyłowo-powietrznej:** regulator utrzymuje zadaną temperaturę za młynem, mieszając powietrze gorące i zimne (klapy).

2.2 Dane

Dostępne dane obejmują okres 1–27 lutego 2026 (26 dni) z próbkowaniem 1 minuta: po 37 440 próbek na młyn, ok. 38 sygnałów na młyn (tagi KKS), oraz pliki pomocnicze (sygnały ogólnokotłowe, KPI kotła, lista punktów pomiarowych, zrzuty ekranów DCS). Kluczowe wykorzystywane sygnały zestawiono w tabeli 1.

Tabela 1: Najważniejsze sygnały zespołu młynowego (przykład dla MW1).

tag KKS	nazwa robocza	jednostka
401HFC10AJ001XQ50:av	moc silnika młyna	kW
401HFB10AF001XQ51:av	prędkość podajnika węgla	%
401HFB10AF001XQ50:av	prąd podajnika węgla	A
401HFE10DF201:me / :spa / :pos	wentylacja: pomiar / zadana / sterowanie	kNm ³ /h, %
401HFE10AA401:pos	położenie kierownicy wentylatora	%
401HHE10FT950:av	temperatura mieszanki za młynem	°C
401HHE10DT901:spa / :pos	temperatura mieszanki: zadana / sterowanie	°C, %
401HFE11AA401:pos / 401HFE12AA401:pos	klapa powietrza gorącego / zimnego	%
401HFC10CP201:av	ciśnienie w młynie	kPa

Przygotowanie danych wymagało obsłużenia kilku pułapek typowych dla eksportów przemysłowych: kodowania `cp1250`, braków zapisanych jako `N_A`, a przede wszystkim *mieszanych formatów czasu w obrębie jednego pliku* (`dd.mm.yyyy HH:MM` oraz `ISO 8601`). Znaczniki czasu parsowano dwuprzebiegowo (listing 1); naiwne użycie automatycznej detekcji formatu prowadziło do cichego przestawienia dnia z miesiącem.


Listing 1: Dwuprzebiegowe parsowanie znaczników czasu (`src/loader.py`).

```
# pliki zawierają mieszane formaty czasu (dd.mm.yyyy HH:MM oraz ISO),
# dlatego parsujemy dwuprzebiegowo zamiast zgadywać dayfirst
t_iso = pd.to_datetime(df[tcol], format="ISO8601", errors="coerce")
t_pl = pd.to_datetime(df[tcol], format="%d.%m.%Y %H:%M", errors="coerce")
df[tcol] = t_iso.fillna(t_pl)
if df[tcol].isna().any():
    raise ValueError(f"nierozpoznane znaczniki czasu w {path.name}")
```

3 Analiza identyfikacyjna obiektu

3.1 Charakterystyka statyczna kanału kierownica → przepływ

Dla każdej minuty pracy młyna dysponujemy punktem pracy (u, y) , gdzie u — położenie kierownicy [%], y — przepływ wentylacji [kNm³/h]. Rysunek 1 przedstawia chmurę punktów pracy MW3 z podziałem na stan zdrowy oraz okna 60 minut przed epizodami zapchania. W stanie zdrowym charakterystyka jest monotoniczna i nasycy się łagodnie; przed zapchaniem punkty pracy przesuwają się w prawo i w dół — ten sam przepływ wymaga znacznie większego otwarcia kierownicy, aż do pracy na ograniczeniu $u = 100\%$ przy malejącym y . Jest to obraz *spadku wzmocnienia statycznego* obiektu wskutek rosnącego oporu przepływu.



Rysunek 1: MW3: charakterystyka statyczna kierownica→przepływ wyznaczona z punktów pracy. Czerwone punkty: 60 min przed epizodami zapchania.

Jako odporny, punktowy estymator wzmocnienia statycznego przyjęto *drożność*

$$k(t) = \frac{y(t)}{u(t)} \quad \left[\frac{\text{kNm}^3/\text{h}}{\%} \right], \quad (1)$$

której medianowe wartości zestawiono w tabeli 2. Spadek drożności przed zapchaniem o 45–83% stanowi fizyczną podstawę całego układu wczesnego ostrzegania.

Tabela 2: Mediana drożności k (wygładzonej medianą 30 min) w stanie zdrowym i w oknach 60 min przed epizodami.

młyn	k — stan zdrowy	k — przed zapchaniem	spadek
MW3	0,506	0,277	–45%
MW4	0,917	0,152	–83%

3.2 Odpowiedź skokowa i model FOPDT toru temperatury

Dane pochodzą z normalnej eksploatacji (identyfikacja bierna), nie można więc zadawać pobudeń. Przeszukano jednak przebiegi wartości zadanych pod kątem *naturalnych skoków* z plateau przed i po zmianie. Wartość zadana wentylacji zmienia się wyłącznie rampami (pochodzi z układu obciążenia bloku), natomiast wartość zadana temperatury mieszanki jest zmieniana przez operatora skokowo — znaleziono po kilkanaście czystych skoków ($|\Delta u| \geq 1^\circ\text{C}$, stabilne plateau 10 min przed i 40 min po, brak wysycenia regulatora).

Znormalizowane odpowiedzi $\Delta y/\Delta u$ uśredniono i dopasowano metodą najmniejszych kwadratów model inercyjny pierwszego rzędu z opóźnieniem (FOPDT):


$$G(s) = \frac{K e^{-sL}}{Ts + 1}, \quad y(t) = K \left(1 - e^{-(t-L)/T} \right) \cdot \mathbf{1}(t \geq L). \quad (2)$$

Wyniki (tab. 3, rys. 2) opisują tor *zamkniętej* pętli regulacji temperatury: dla MW3 wzmocnienie statyczne $K \approx 1$ oznacza poprawne nadążanie za wartością zadaną, a stała czasowa $T \approx 23$ min

— wolną dynamikę toru cieplnego (mieszanie powietrza, pojemność cieplna młyna). Charakterystyczna jest mała wartość opóźnienia czystego $L \approx 1$ min, zgodna z transportem mieszanki przez młyn.

Tabela 3: Parametry FOPDT odpowiedzi toru regulacji temperatury mieszanki na skok wartości zadanej.

młyn	liczba skoków	K [–]	T [min]	L [min]
MW3	15	1,01	22,7	1,0
MW4	15	0,82	6,8	0,4



Rysunek 2: MW3: uśredniona odpowiedź toru regulacji temperatury mieszanki na skok wartości zadanej oraz dopasowany model FOPDT. Cienkie linie — pojedyncze skoki (zakłócenia eksploatacyjne).

Rozrzut pojedynczych odpowiedzi (cienkie linie) ilustruje koszt identyfikacji biernej: pojedynczy „eksperyment” jest silnie zakłócony zmianami obciążenia, dopiero uśrednienie kilkunastu skoków daje gładką odpowiedź.

3.3 Rekurencyjna identyfikacja ARX i problem pętli zamkniętej

Do śledzenia zmian dynamiki kanału kierownica→przepływ zastosowano model ARX(1,1)


$$y(t) = a y(t-1) + b u(t-1) + e(t), \quad \hat{K}_{ARX} = \frac{\hat{b}}{1 - \hat{a}}, \quad (3)$$

estymowany rekurencyjną metodą najmniejszych kwadratów (RLS) z wykładniczym zapominaniem $\lambda = 0,998$ (listing 2).

Listing 2: RLS z zapominaniem (src/identyfikacja.py).

```
def rls_arx(u, y, lam=0.998):
    """ARX(1,1): y(t) = a*y(t-1) + b*u(t-1)."""
    theta = np.zeros(2); P = np.eye(2) * 1000.0
    for t in range(1, len(y)):
        phi = np.array([y[t-1], u[t-1]])
        k = P @ phi / (lam + phi @ P @ phi)
        theta = theta + k * (y[t] - phi @ theta)
        P = (P - np.outer(k, phi @ P)) / lam
```

Wynik (rys. 3, dolny panel) jest pouczający *negatywnie*: estymata $\hat{K}_{ARX}$ przyjmuje dla MW3 wartości ujemne przez ok. 20% czasu pracy. Jest to klasyczne obciążenie identyfikacji bezpośredniej w zamkniętej pętli regulacji: przy stałej wartości zadanej jedynym źródłem zmienności są zakłócenia wyjścia, na które regulator odpowiada ruchem sterowania w przeciwnym kierunku — korelacja $u-y$ odzwierciedla wtedy (odwrócony) regulator, a nie obiekt. Wiarygodna estymata pojawia się tylko w okresach bogatszego pobudzenia (zmiany zadanej). W tej sytuacji prosty iloraz punktu pracy (1) (środkowy panel) okazuje się odporniejszym wskaźnikiem wzmocnienia statycznego i to on — a nie $\hat{K}_{ARX}$ — został użyty jako cecha modeli predykcyjnych.




Rysunek 3: MW3, luty 2026: przepływ wentylacji (góra), drożność y/u (środek) oraz estymata RLS wzmocnienia statycznego ARX (dół). Czerwone pasma — epizody zapchania. Widoczny spadek drożności przed epizodami oraz obciążenie estymaty ARX w pętli zamkniętej (wartości ujemne).

Wniosek identyfikacyjny. Zapchanie młyna jest obserwowalne jako *dryf parametru obiektu* — spadek wzmocnienia statycznego kanału wentylacji — na długo przed wystąpieniem skutków (przeciążenia napędu, utraty temperatury mieszanki). Zadanie predykcji zapchania można więc sformułować jako detekcję zmiany parametrów obiektu na podstawie sygnałów diagnostycznych.

4 Definicja zdarzenia i etykietowanie danych

4.1 Anatomia epizodu

W danych nie ma dziennika zdarzeń, dlatego epizody zapchania wyznaczono sygnałowo i zweryfikowano wizualnie. Rysunek 4 przedstawia modelowy epizod (MW3, 15.02.2026): (I) regulator wentylacji stopniowo otwiera kierownicę aż do wysycenia 100%; (II) mimo wysycenia przepływ spada poniżej wartości zadanej (deficyt), moc młyna rośnie, temperatura mieszanki spada poniżej zadanej; (III) automatyka cyklicznie odcina podajnik węgla (przebieg piłokształtny), młyn się oczyszcza, kierownica schodzi z ograniczenia.



Rysunek 4: Anatomia epizodu zapchania (MW3, 15.02.2026, 00:00–06:30).

4.2 Sygnałowa definicja zdarzenia

Zdarzenie „zapchanie” zdefiniowano jako spełnienie — w czasie pracy młyna ($\text{moc} > 20 \text{ kW}$) — któregokolwiek z warunków:

- D1** deficyt wentylacji $d(t) = \frac{y_{sp}(t) - y(t)}{y_{sp}(t)} > 0,2$ nieprzerwanie przez ≥ 5 min przy sterowaniu $\geq 98\%$,
- D2** awaryjne odciążenie: spadek prędkości podajnika o ≥ 25 pkt w ≤ 3 min, podczas gdy młyn nadal pracuje,
- D3** przeciążenie: moc młyna powyżej kwantyla 99,5% rozkładu w pracy przy deficycie $> 0,1$.


Minuty zdarzenia sklejano w epizody (przerwa < 90 min $\Rightarrow$ ten sam epizod). Epizod uznano za **silny**, jeśli zawiera ≥ 3 min warunku D1 — ma wtedy fazę narastania, a więc jest *fizycznie przewidywalny*. Pozostałe (nagłe odciążenia bez prekursorów) wyłączono z uczenia i oceny. W lutym 2026 zidentyfikowano **5 silnych epizodów** (tab. 4) oraz 7 mikrozdzień; wszystkie wystąpiły na MW3 i MW4.

Tabela 4: Silne epizody zapchania (etykiety do uczenia).

młyn	początek	koniec	czas trwania
MW3	05.02 11:54	05.02 14:16	143 min
MW3	09.02 04:39	09.02 05:00	22 min
MW3	11.02 09:40	11.02 10:15	36 min
MW3	15.02 02:38	15.02 04:11	94 min
MW4	19.02 18:15	19.02 19:19	65 min

4.3 Schemat etykietowania

Cel predykcyjny sformułowano jako klasyfikację binarną: $y(t) = 1$, jeśli silny epizod rozpocznie się w ciągu horyzontu $H = 60$ min (rys. 5). Z uczenia wyłączono: minuty postoju młyna, 60 min po każdym rozruchu, czas trwania epizodów oraz 60 min rekonwalescencji po nich. Zbiór uczący (4 młyny łącznie, cechy niezależne od numeru młyna) liczy 131 719 minut, w tym 300 pozytywnych (0,23%).



Rysunek 5: Schemat etykietowania względem początku zdarzenia.

5 Modele predykcyjne

5.1 Cechy

Zbudowano 39 cech liczonych wyłącznie z przeszłości (bez wycieku przyszłości): poziomy sygnałów, zmiany i średnie kroczące w oknach 15/30/60 min oraz cechy fizyczne wynikające wprost z analizy identyfikacyjnej (listing 3): drożność (1), deficyt wentylacji, energochłonność mielenia (moc na jednostkę strumienia węgla), liczba minut wysycenia regulatora w ostatniej godzinie, niestabilność mocy.

Listing 3: Kluczowe cechy fizyczne (src/features.py).

```
deficyt = (df["went_zadana"] - df["went_pomiar"]) / df["went_zadana"].clip(lower=1)
droznosc = df["went_pomiar"] / df["went_sterowanie"].clip(lower=1)
f["moc_na_wegiel"] = df["moc_mlyna"] / df["podajnik_predkosc"].clip(lower=1)
f["t_miesz_odchylka"] = df["t_mieszanki"] - df["t_mieszanki_zadana"]
f["sat_min60"] = (df["went_sterowanie"] >= 98).rolling(60).sum()
f["deficyt_min30"] = (deficyt > 0.10).rolling(30).sum()
f["moc_std30"] = df["moc_mlyna"].rolling(30).std()
```

5.2 Reguła fizyczna (poziom odniesienia)

Najprostszy detektor zbudowano wprost z fizyki zjawiska: alarm, gdy w ostatniej godzinie regulator wentylacji był wysycony przez ≥ 20 min i średni deficyt 15-minutowy przekracza 8%. Reguła nie wymaga uczenia i stanowi poziom odniesienia dla modeli statystycznych.

5.3 LightGBM

Jako model główny wybrano gradient boosting (LightGBM) z silną regularyzacją (300 drzew o maks. 15 liściach, `min_child_samples=100`, podpróbkowanie wierszy i kolumn, waga klasy pozytywnej ograniczona do 30). Wybór wynika z liczebności zdarzeń: przy 5 epizodach o jakości decydują cechy, a nie pojemność modelu; boosting na cechach fizycznych jest interpretowalny (ważności cech) i trenuje się w sekundy na CPU.

5.4 Sieci neuronowe (kontrprzykład)

Aby empirycznie zweryfikować hipotezę o braku uzasadnienia dla uczenia głębokiego przy tej liczbie zdarzeń, wytrenowano w identycznym reżimie walidacyjnym dwa warianty:

- **MLP** (64–32, dropout 0,3) na *tych samych* 39 cechach — izoluje wpływ architektury od inżynierii cech,
- **LSTM** (32 jedn., głowica 16) na surowych sekwencjach $60 \text{ min} \times 12$ sygnałów — test, czy sieć sama „odkryje” cechy z surowych przebiegów (listing 4).

Listing 4: Architektura LSTM (`src/nn_experiment.py`).

```
class LSTMNet(nn.Module):
    def __init__(self, n_sig, hidden=32):
        super().__init__()
        self.lstm = nn.LSTM(n_sig, hidden, batch_first=True)
        self.head = nn.Sequential(nn.Linear(hidden, 16), nn.ReLU(), nn.Linear(16, 1))

    def forward(self, x):
        out, _ = self.lstm(x)
        return self.head(out[:, -1]).squeeze(-1)
```

Niezbalansowanie klas (0,23% pozytywnych) obsłużono wagą klasy pozytywnej w funkcji straty (`BCEWithLogitsLoss(pos_weight)`, ograniczenie do 30) oraz — dla LSTM — podpróbkowaniem negatywów w zbiorze uczącym (wszystkie pozytywne zachowane).

6 Metodyka oceny

Walidacja. Dane są szeregiem czasowym, więc zwykła walidacja krzyżowa zawyżałaby wyniki (wyciek przez okna kroczące). Zastosowano *GroupKFold po dniach kalendarzowych*: (a) wariant 5-krotny — do uczciwego porównania trzech modeli (koszt uczenia sieci), (b) wariant leave-one-day-out (27 foldów) — do oceny modelu finalnego. Wszystkie podawane predykcje są pozapróbkowe (out-of-fold).

Metryki minutowe. PR-AUC (average precision) i ROC-AUC liczone na poziomie pojedynczych minut. Przy 0,23% klasy pozytywnej losowy klasyfikator ma PR-AUC $\approx 0,002$.


Metryki zdarzeniowe. Z punktu widzenia obsługi liczy się: (a) czy epizod został wykryty w oknie ostrzegania (alarm = co najmniej 3 kolejne minuty ze $\text{score} \geq \text{progu}$), (b) czas wyprzedzenia względem początku zdarzenia, (c) liczba fałszywych serii alarmowych na dobę pracy młyna. Wyjścia modeli wygładzono medianą kroczącą 5 min.

7 Wyniki


7.1 Porównanie modeli

Tabela 5: Porównanie modeli — identyczna walidacja 5-fold po dniach, próg alarmu 0,5. FA = fałszywe serie alarmowe na dobę i młyn. Reguła fizyczna oceniona na tym samym zbiorze; LODO = leave-one-day-out.

model	PR-AUC	ROC-AUC	wykryte	wyprzedz. [min]	FA
reguła fizyczna	—	—	5/5	48,8	0,074
LightGBM (cechy)	0,286	0,931	4/5	33,0	0,046
MLP (cechy)	0,362	0,859	4/5	50,5	0,074
LSTM (sekwencje)	0,206	0,975	4/5	42,0	0,102
LightGBM, LODO (27 foldów)	0,359	0,953	5/5	30,0	0,056
hybryda: LightGBM $\vee$ reguła, LODO	—	—	5/5	51,0	0,093




Rysunek 6: Krzywe precyzja-czułość trzech modeli (minutowo, predykcje pozapróbkowe, walidacja 5-fold po dniach).



Rysunek 7: Wyjście modelu LightGBM (walidacja leave-one-day-out) dla MW3 i MW4. Czerwone punkty — minuty okien ostrzegania przed epizodami.

Model finalny (LightGBM, walidacja leave-one-day-out, próg 0,5, alarm po 3 kolejnych minutach) wykrywa **5/5** silnych epizodów ze średnim wyprzedzeniem **30 min** przy **0,056** fałszywej serii na dobę i młyn. Hybryda z regułą fizyczną (alarm, gdy którykolwiek człon zgłasza) wydłuża wyprzedzenie do **51 min** kosztem nieznacznego wzrostu liczby fałszywych alarmów. Najważniejsze cechy modelu (rys. 8) pokrywają się z analizą identyfikacyjną: poziom i trend przepływu, średnia moc młyna, odchyłka temperatury mieszanki, liczba minut deficytu i wysycenia.




Rysunek 8: Ważności cech finalnego modelu LightGBM.

7.2 Sieci neuronowe — analiza kontrprzykładu

Tabela 5 pokazuje, że żaden z wariantów sieci nie dominuje spójnie: MLP ma najwyższe PR-AUC, ale najniższe ROC-AUC; LSTM odwrotnie — najwyższe ROC-AUC przy najniższym PR-AUC i *dwukrotnie* większej liczbie fałszywych alarmów niż LightGBM. Zdarzeniowo wszystkie trzy modele wykrywają te same 4/5 epizodów.

Niestabilność uczenia sieci przy 5 zdarzeniach (fold 4 nie zawiera żadnego zdarzenia)



Rysunek 9: Krzywe uczenia sieci: average precision na foldzie testowym po każdej epoce. Fold 4 nie zawiera żadnego zdarzenia (AP nieokreślone).

Istotniejsza od średnich wyników jest *niestabilność* (rys. 9): dla LSTM wynik na foldzie testowym oscyluje między epokami w zakresie 0,07–1,0 (fold 2: AP = 0,60 w epoce 4 i 0,10 w epoce 5), a dla MLP fold 3 wykazuje systematyczne przeuczanie. Przy 5 zdarzeniach: (a) nie istnieje sensowny zbiór walidacyjny do wyboru epoki/architektury — każda decyzja jest de facto dopasowaniem do zbioru testowego; (b) różnice między modelami mieszczą się w wariancji pojedynczego epizodu; (c) rozbieżność między AP liczoną osobno na foldach (0,5–1,0) a AP zbiorczym (0,2–0,36) ujawnia dodatkowo problem niekalibrowanych score’ów między foldami. Wniosek: **przy obecnej liczbie zdarzeń wybór sieci neuronowej nie znajduje statystycznego uzasadnienia**, a prostszy model na cechach fizycznych jest preferowany także ze względu na interpretowalność i koszt wdrożenia. Sieci sekwencyjne (LSTM/TCN) mogą zyskać przewagę dopiero przy zbiorze rzędu kilkudziesięciu–kilkuset epizodów (6–12 miesięcy danych z kilku bloków).

8 Dyskusja

Spójność wyników z fizyką. Wszystkie trzy niezależne spojrzenia — analiza identyfikacyjna (spadek wzmocnienia statycznego), reguła fizyczna (wysycenie + deficyt) i ważności cech modelu — wskazują ten sam mechanizm: zapchanie rozwija się przez dziesiątki minut jako narastający opór przepływu kompensowany przez regulator aż do wysycenia. To uzasadnia zaufanie do modelu mimo małej liczby zdarzeń.

Ograniczenia. (a) Etykiety wyznaczono sygnałowo — wymagają potwierdzenia dziennikiem zdarzeń DCS; (b) 5 epizodów z jednego miesiąca i dwóch młynów to studium wykonalności, nie walidacja produkcyjna; (c) mikrozdarzeń (nagłych odcięć bez fazy narastania) z definicji nie da się przewidzieć z minutowych danych procesowych; (d) identyfikacja przebiegała w zamkniętej pętli regulacji — część charakterystyk (FOPDT) opisuje układ regulacji, a nie sam obiekt; pełna identyfikacja obiektu wymagałaby eksperymentu czynnego.

Wdrożenie. Model przelicza pojedynczą minutę w milisekundach na CPU. Proponowany układ: liczenie cech w oknie kroczącym na strumieniu 1-min z DCS, alarm po 3 kolejnych minutach score $\geq 0,5$, równoległe reguła fizyczna jako niezależny watchdog (hybryda — najdłuższe wyprzedzenie).

9 Wnioski

1. Zapchanie młyna węglowego jest w danych procesowych obserwowalne jako **dryf wzmocnienia statycznego** kanału kierownica $\rightarrow$ przepływ (spadek drożności o 45–83%) na 1–2 h

przed kulminacją zdarzenia.

2. Tor regulacji temperatury mieszanki daje się opisać modelem FOPDT ($K \approx 1$, $T \approx 23$ min dla MW3) wyznaczonym z naturalnych skoków wartości zadanej; bezpośrednia identyfikacja ARX w pętli zamkniętej jest obciążona (ujemne estymaty wzmocnienia) i wymaga ostrożnej interpretacji.
3. Finalny model (LightGBM na 39 cechach fizycznych, walidacja leave-one-day-out) wykrywa **5/5** epizodów ze średnim wyprzedzeniem **30 min** przy **0,06** fałszywej serii na dobę i młyn; hybryda z regułą fizyczną wydłuża wyprzedzenie do **51 min**.
4. Eksperyment kontrolny z sieciami neuronowymi (MLP, LSTM) potwierdził hipotezę: przy 5 zdarzeniach sieci nie dają spójnej przewagi, a ich uczenie jest niestabilne — o jakości decyduje inżynieria cech zakorzeniona w fizyce obiektu, nie pojemność modelu.
5. Dalsze prace: potwierdzenie etykiet dziennikiem zdarzeń, wydłużenie horyzontu danych do 6–12 miesięcy, dołączenie sygnałów ogólnokotłowych (obciążenie, jakość węgla) oraz — przy większej liczbie epizodów — ponowna ocena modeli sekwencyjnych.

A Reprodukacja wyników

Środowisko: Python 3.12 (WSL2 Ubuntu 24.04), pakiety `pandas`, `scikit-learn`, `lightgbm`, `torch` (CPU), `scipy`, `matplotlib`. GPU nie jest wymagane. Kolejność uruchamiania skryptów oraz strukturę projektu opisuje plik `README.md`; pełny kod źródłowy znajduje się w katalogu `src/`, artefakty (model, wyniki, ryciny) w katalogu `work/`.